Application of Word Embeddings in Analysis of Chinese Internet Buzzwords

基于动态词向量的中文互联网用语语义分析

胡海音　刘玉　糜欣贝

时间：2026.11

目录

CONTENT

词汇语义学

互联网用语及语义变化?

LLM如何理解语言?

基于词向量的语义分析

局限性与延申

Lexical Semantics
词汇语义学

“第一部分” PART ONE

Definition of Lexical Semantics
词汇语义学的定义

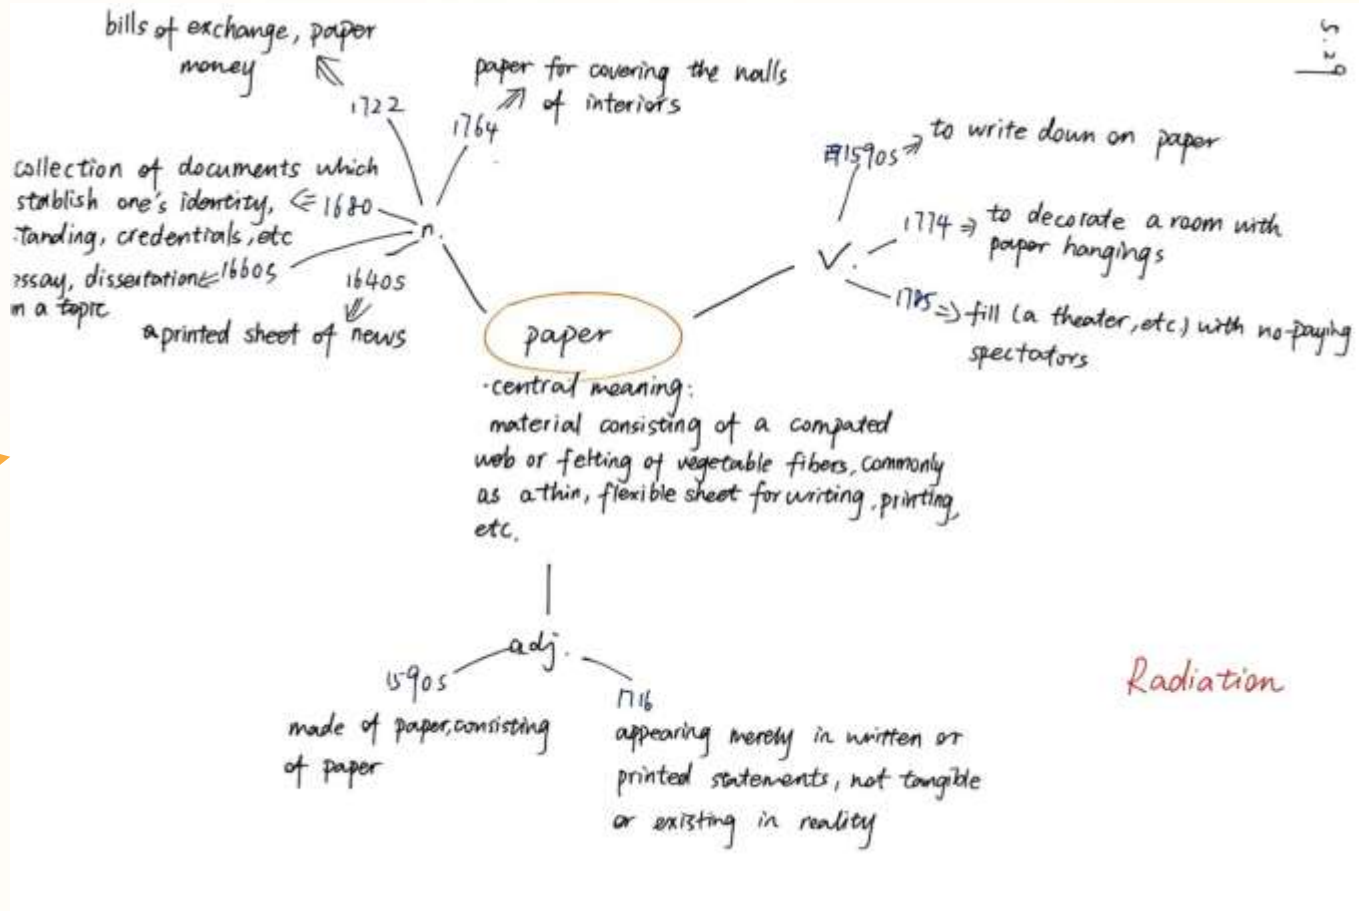
Lexical semantics is a subfield of semantics that studies the meaning of lexical items (words), the semantic relations that hold between words (such as synonymy, antonymy and hyponymy), and the way word meanings are structured, extended and restricted.

词汇语义学是语义学的分支学科，研究词汇项（词）的意义、词与词之间的语义关系（如上下位关系、同义关系、反义关系），以及词义的结构方式、引申与制约规律。



Polysemy 一词多义

- Polysemy is the phenomenon whereby a single word form carries two or more senses that are interrelated, being linked by cognitive or historical connections.
- 多义现象：一个单一词形承载两个或以上相互关联、有认知或历史联系的义项。
- 举例：Paper
- ⚠ 与同形异义（homonymy）区分：bank ①河岸 ②银行，两义来源不同、无引申联系，属同形异义。



Synonymy 同义关系

Synonymy is the sense relation whereby two or more distinct word forms have essentially the same core meaning and can substitute for each other in a specific context
同义关系：两个或多个词形不同，但在特定语境下核心语义基本相同、可以互相替换的语义关系。

举例：buy / purchase

两者概念意义一致（“以获得所有权的付款行为”），差别在语体色彩与正式程度，属语体同义。

Antonymy 反义关系

Antonymy is the sense relation between two words that have opposite or contrasting meanings.
反义关系：两个词的词形不同，意义相反或形成对立关系的语义关系。

举例：hot / cold（热 / 冷）

两者在温度这一语义维度上形成对立关系，但并不意味着所有情况下，一个词的意义都完全排斥另一个词。

Traditional Methods of Semantic Analysis
传统语义分析方法

方法一：词典释义与义项划分（dictionary definition & sense enumeration）

定义：依据词典编纂原则，把一个词的语义拆分成若干离散、独立的义项，用定义式语言逐个描述并排列，以此确定该词的语义结构。

举例：crane

义项①：a tall water bird with long legs and a long neck（鹤，动物）

义项②：a machine for lifting heavy objects（起重机，机械）

方法二：基于语境的语义分析（context-based semantic analysis）

定义：通过分析词语所处的上下文、搭配和语篇环境，判定该词在实际使用中激活的是哪一个具体义项，即用语境消解歧义。

举例：crane

- The crane stood in the shallow water looking for fish.（语境：湿地、找鱼）→ 义项① 鹤
- The crane lifted the container onto the truck.（语境：集装箱、卡车）→ 义项② 起重机

Traditional Methods of Semantic Analysis
传统语义分析方法

方法三：基于人工标注的语料分析
（manually annotated corpus analysis）

定义：研究者阅读真实语料，人工为句中每个目标词逐条标注其对应义项或语义标签，再统计归纳词义分布与使用规律。

举例：virus

语言学团队阅读大量科技与医疗新闻，人工把每处 virus 标注为：

- 【生物病毒】The virus spreads through droplets.
- 【计算机病毒】A new virus infected thousands of computers.

随后统计两个义项在不同语域中的出现频次，得出词义分布规律。

表2　两类企业致辞语言特征对比

语言特征	国有企业	民营企业
机构自称（公司、本行）	66（18.1）	1（0.3）
第一人称代词（我们、我）	0（0.0）	119（33.7）
第二人称代词（你们、你）	0（0.0）	10（2.8）
互动称呼（亲爱的、大家、谢谢等）	0（0.0）	19（5.4）
高量值情态（必须、坚决）	12（3.3）	3（0.8）
中量值情态（要、将）	15（4.1）	1（0.3）
低量值情态（会、希望、愿意等）	0（0.0）	18（5.1）
积极情感词	200（54.8）	125（35.4）
消极情感词	29（8.0）	58（16.4）
消极词占情感词比例	12.7%	31.7%

注：括号内为每千字标准化频次。

Traditional Methods of Semantic Analysis
传统语义分析方法

◆局限性

- **义项边界模糊、切分主观**

例：nice 在《牛津》里划分为“令人愉快的/友好的/精细的”多义项，而在《朗文》中合并为两个义项。同一词义，两本权威词典的义项数量和边界并不一致，说明义项切分缺乏客观标准。

- **静态化缺陷，难以捕捉动态引申义**

例：网络语境中“这瓜保熟吗”里的“瓜”（八卦、内幕）、“上头”（让人着迷）等新义，在传统词典出版时都尚未收录，词典释义无法及时覆盖。

- **缺少量化能力，无法刻画词义的概率与相似度**

例：词典只能说明 bank 有“河岸”“银行”两义，但不能给出在真实语料中“银行”义约占 92%、“河岸”义约占 8% 这样的量化分布，也无法计算两个义项之间的语义距离。

Internet Slang And Semantic Changes
互联网用语及语义变化

第二部分 PART TWO

Features of Internet Slang
网络热词的特点

★ **1）Spreads quickly, and contexts of use change quickly**
传播速度快，使用场景变化快

- The internet removes geographic barriers, so a meme or buzzword can spread across the web in just a few hours.
- 互联网打破了地域限制，一个梗或热词可以在几小时内传遍全网。

★ 破防了，最初是游戏术语（破除防御），现在广泛用于形容心理受到冲击、感动或悲伤，且热度起伏极大。

★我画地为牢啊厉娜



Features of Internet Slang
网络热词的特点

★ **2) Depends on social context, group culture, and specific events**

依赖社交语境、群体文化和特定事件

★ Without knowing the community behind a term or the latest news, outsiders often have no idea what many internet buzzwords mean.

很多网络热词如果不了解背后的圈子或刚刚发生的新闻，外人根本听不懂。

★ “我推”或“我担”

“推”源于日本偶像文化（Oshi），指代自己最支持、最喜爱的偶像；“担”则指代自己负责或支持的成员。

二次元的同学们一定对这个词语不陌生。

“我是xx推（我喜欢xx）”

“我推是很出色的（喜欢的人很棒）”

“我推最棒了（喜欢的人是最好的）”

最初是粉丝们用于称呼自己喜爱的偶像成员，称为「我推成员（推しメン）」，意思为最推崇的成员

お

「推し」是指喜欢到想推荐给别人的人(尤其是爱豆和演员)或东西。中文可以翻译为支持的人，或者喜欢的人(或东西)。

到底是怎么演变成现在的「推し」呢？



来源于动词的「推す」，但现在已经被名词化。

变成了「推し」，

中文可以译为“我推”。

Features of Internet Slang
网络热词的特点

3) Highly dependent on context, with flexible meanings
具有较强的语境依赖性和语义灵活性

★ The same word can mean completely different things in different sentences or with different memes.

★ 同一个词在不同的句子、不同的表情包搭配下，意思可能完全相反。它不像字典里的词那样定义死板，而是随着使用者的情绪流动。

- 例子：比如“呵呵”，在长辈看来可能是礼貌的微笑，但在年轻人的网络语境中，往往代表敷衍、无语甚至嘲讽。



Types of Meaning Change in Internet Slang
网络热词的语义变化类型

1）Semantic broadening: An existing word takes on a wider range of uses

语义扩展: 原有词语获得更广泛的用法

★ The original meaning remains, but the term applies to more things. It shifts from referring to a specific object to a broader phenomenon or abstract concept.

★ 词的本义没有丢，但是适用范围变大了，从指代具体事物变成了指代一类现象或抽象概念。



★ 塌房 原义非常具体，指建筑物倒塌。在网络流行语中，它获得了更广泛的用法，特指“偶像明星因负面新闻导致人设崩塌”，后来这个概念被迅速泛化。

它的适用范围从“具体的房子”扩展到了“抽象的心理预期落空”，从“娱乐圈”扩展到了“万物皆可塌”。

Types of Meaning Change in Internet Slang
网络热词的语义变化类型

★ 2) **Semantic shift**: A word gradually takes on a new meaning that differs from its original one

语义转移：词语逐渐获得不同于原义的新含义

- 这是最彻底的变化，词的重心发生了偏移，新义项逐渐取代或独立于旧义项。

★ 种草 原义是把草种在地里。现在的核心含义变成了“向别人推荐某物，激起别人的购买欲”。

- 虽然还保留了一点“植入”的意象，但已经完全变成了一个消费行为动词。



Types of Meaning Change in Internet Slang
网络热词的语义变化类型

★ **3) Pragmatic function shift:** Expressing humor, sarcasm, solidarity, and other emotions

语用功能变化：表达调侃、讽刺、认同等情绪

★ A word's role in referring to things weakens while its emotional role grows stronger.

★ 词语的指代功能减弱，情感表达功能增强。人们用这个词不是为了说明事实，而是为了站队、发泄情绪或进行社交互动。



★ 牛马 现在主要用于表达调侃、讽刺或自嘲。

年轻人用“牛马”自称，往往带有一种黑色幽默，用来消解职场高压带来的无力感，更是一种群体身份的认同和情绪宣泄

PART THREE

How Do LLMs Understand Language?



How Do LLMs Understand the New Meanings of Internet Slang?

TOKEN

English：It is unbelievable that you persuade her.

It is unbelievable that you persuade persuade her.

[3206, 382, 83614, 484, 481, 101817, 1335, 13]

Token ID

中文：我不敢相信你居然说服了她

我不敢相信你居然说服了她

[7522, 3428, 97765, 179058, 12370, 38873, 16125, 9631……

4069 dim

我 [32, 44, 52……132, 21]

不 [12, 6, 327……11, 171]

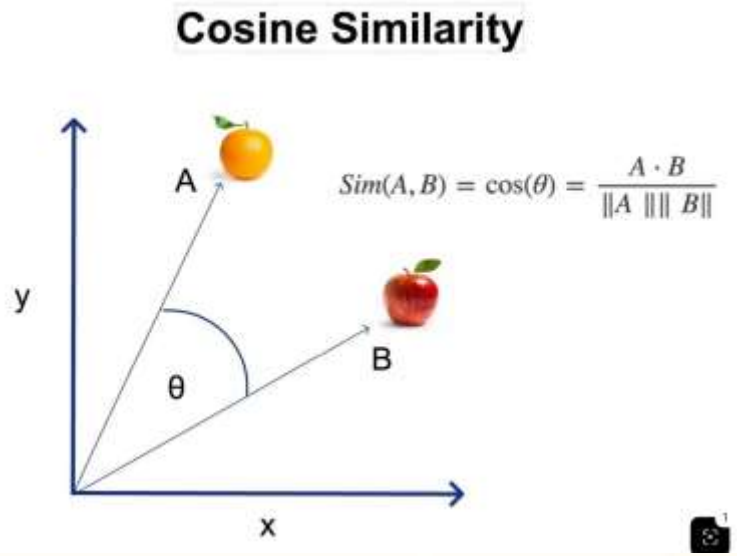
敢 [81, 67, 27……211, 71]

……

Word Embeddings
词向量

Cosine Similarity





橘子　　苹果

计算 Cosine Similarity

$$\cos(H_1, H_2) = \frac{H_1 \cdot H_2}{\|H_1\| \|H_2\|}$$

Static Word Embeddings
静态词向量

Word2Vec

同一个词，不管在什么句子里，**向量都一样**

Contextual Word Embeddings
动态词向量

BERT/GPT

同一个词，在不同句子里，**向量不同**

我昨天吃了一个苹果　&　苹果发布了iPhone Duo

“苹果”→ [0.21，-0.08，0.77…]

“苹果”→ [0.31，-0.43，0.65…]

PART FOUR

Apply Word Embeddings in Semantic Analysis

Dataset Construction

Web Crawling 网络爬虫

网站：b站

- **Target Words: 4 characters**
- **Raw data:**
  - **automatic web crawling**
  - **4000-7000 from 2016 to 2026**
- **Process and clean**

[raw #1] 类型: comment 字数: 40 点赞: 1 来源检索词: 绷
—— 正文 ——
回复 @ok绷blue:表示只听到台下妹子的笑声 **removed**

[raw #2] 类型: comment 字数: 161 点赞: 1298 来源检索词: 绷不住
—— 正文 ——
……流量没有很好，老粉有点着急。个人感觉“绷不住了啦”几个字可以放最后……

[raw #3] 类型: comment 字数: 16 点赞: 328 来源检索词: 绷住
—— 正文 ——
钱….已经被上一个绷住的人拿走了

[raw #4] 类型: comment 字数: 2 点赞: 58 来源检索词: 绷不住
—— 正文 ——
难绷

[raw #5] 类型: comment 字数: 16 点赞: 525 来源检索词: 绷不住
—— 正文 ——
但是啊，一脸难绷啊2333（草）

Model

chinese-roberta-wwm-ext：12 层 / 768 维

Model	Year	Hidden Size	Type	Architecture	Parameter
Qwen3.5-9B	2026	4096	Generative LLM	Decoder-based	9B
Llama-3-Chinese-8B	2023	4096	Generative LLM	Decoder-based	8B
MacBERT-base	2020	768	Pre-trained LM	Encoder-only	102M
chinese-roberta-wwm-ext	2019	768	Pre-trained LM	Encoder-only	102M

Clustering Method

❖ CDPC + CLARA

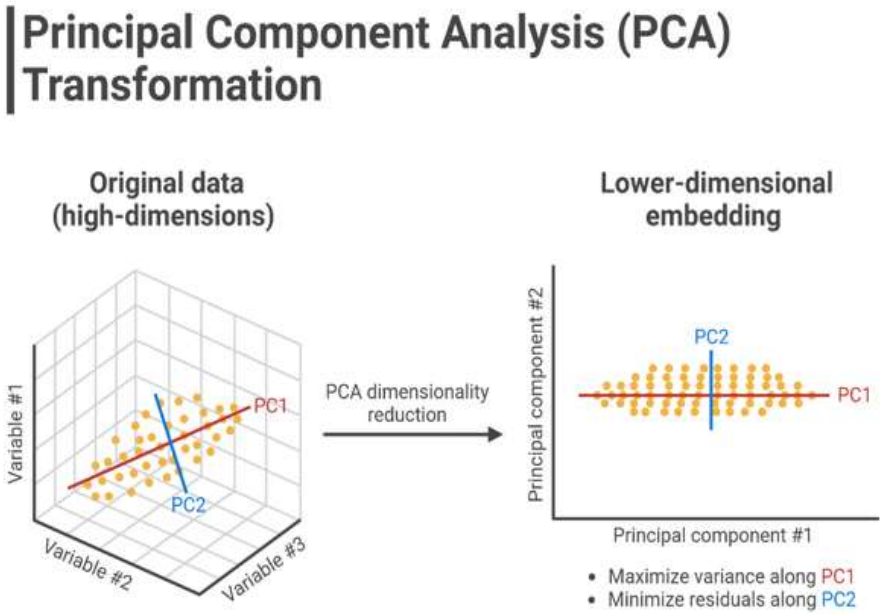
Meichun Liu. Hongbin Qing. *Language, Cognition, and LLM: How to apply LLM to lexical semantics research?* 中国语言学暑校，2026-07-30. 第27页

- ➢Automatic Clustering + Data Interpretability
- ➢**CDPC:** automatically determines the number of **clusters** (***k***)
- ➢**CLARA:** identifies actual cluster centers and assigns each embedding to its nearest centroid. **多次抽样后聚类**
- ➢Each cluster represents a sense of a word, following the assumption of prior studies

Feature Indentification

❖ PCA(Principal Component Analysis)

- PCA helps to **compute the most important dimensions** affecting the word sense clustering results



❖ Data visualization

- All embeddings are projected and extracted from the 768-dimension model
- Tool:

不不不，你前面已经说过接近的答案了，只是没完全说出来

啊！是不是因为法国人有 **法棍（baguette）**，所以嘴被法棍塞住了，想笑也笑不出来，只能绷住？😂

还是说……法国人有 French kiss，嘴巴太忙了，没空笑？🤣

那我告诉你吧，bonjour，绷住。

……

BONJOUR，绷住。 FR

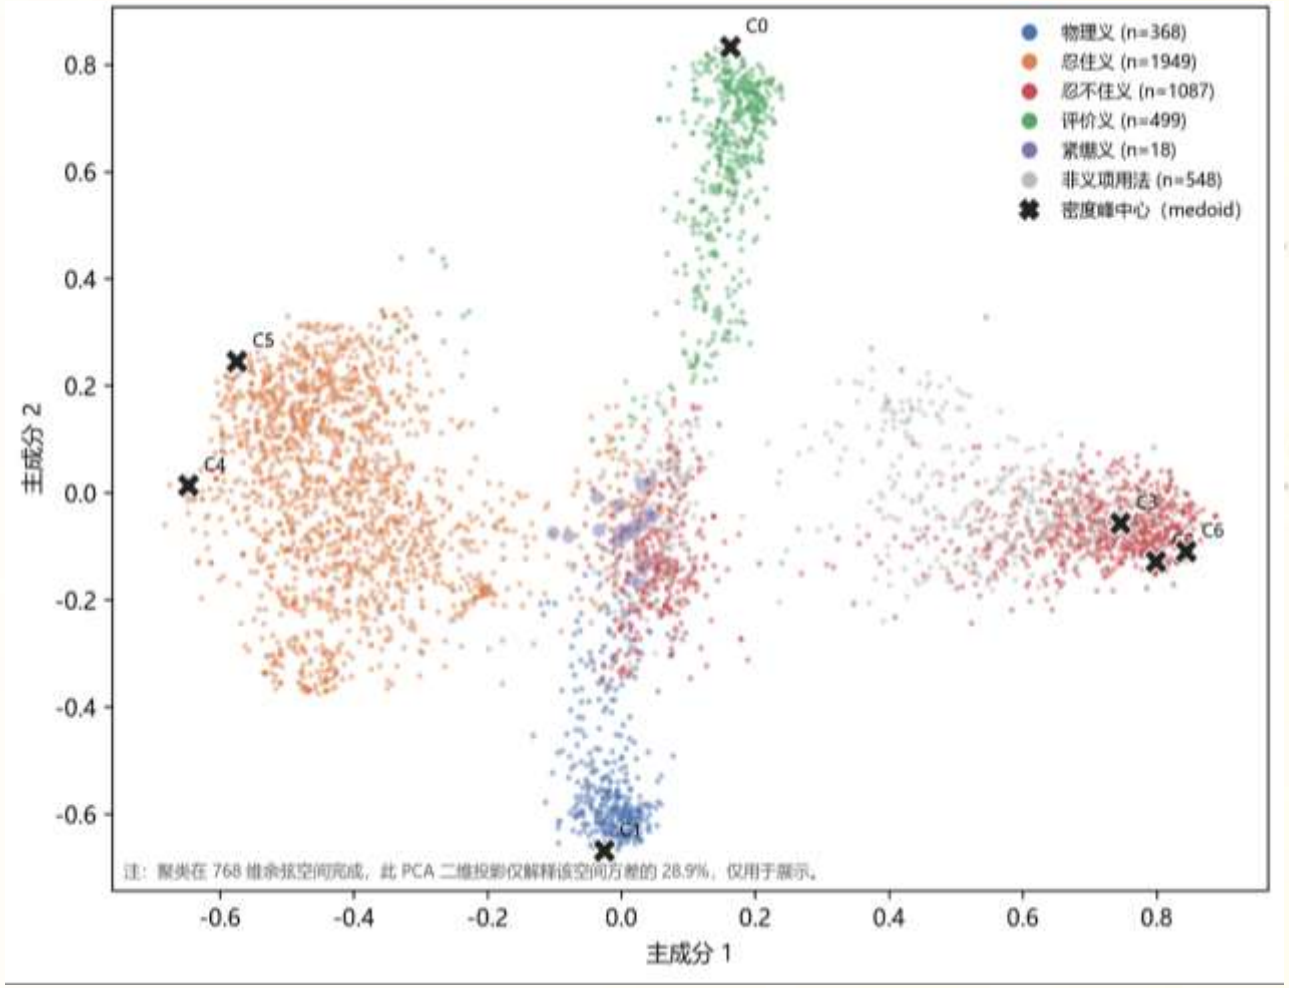
我居然绕了这么大一圈，愣是没想到这个。

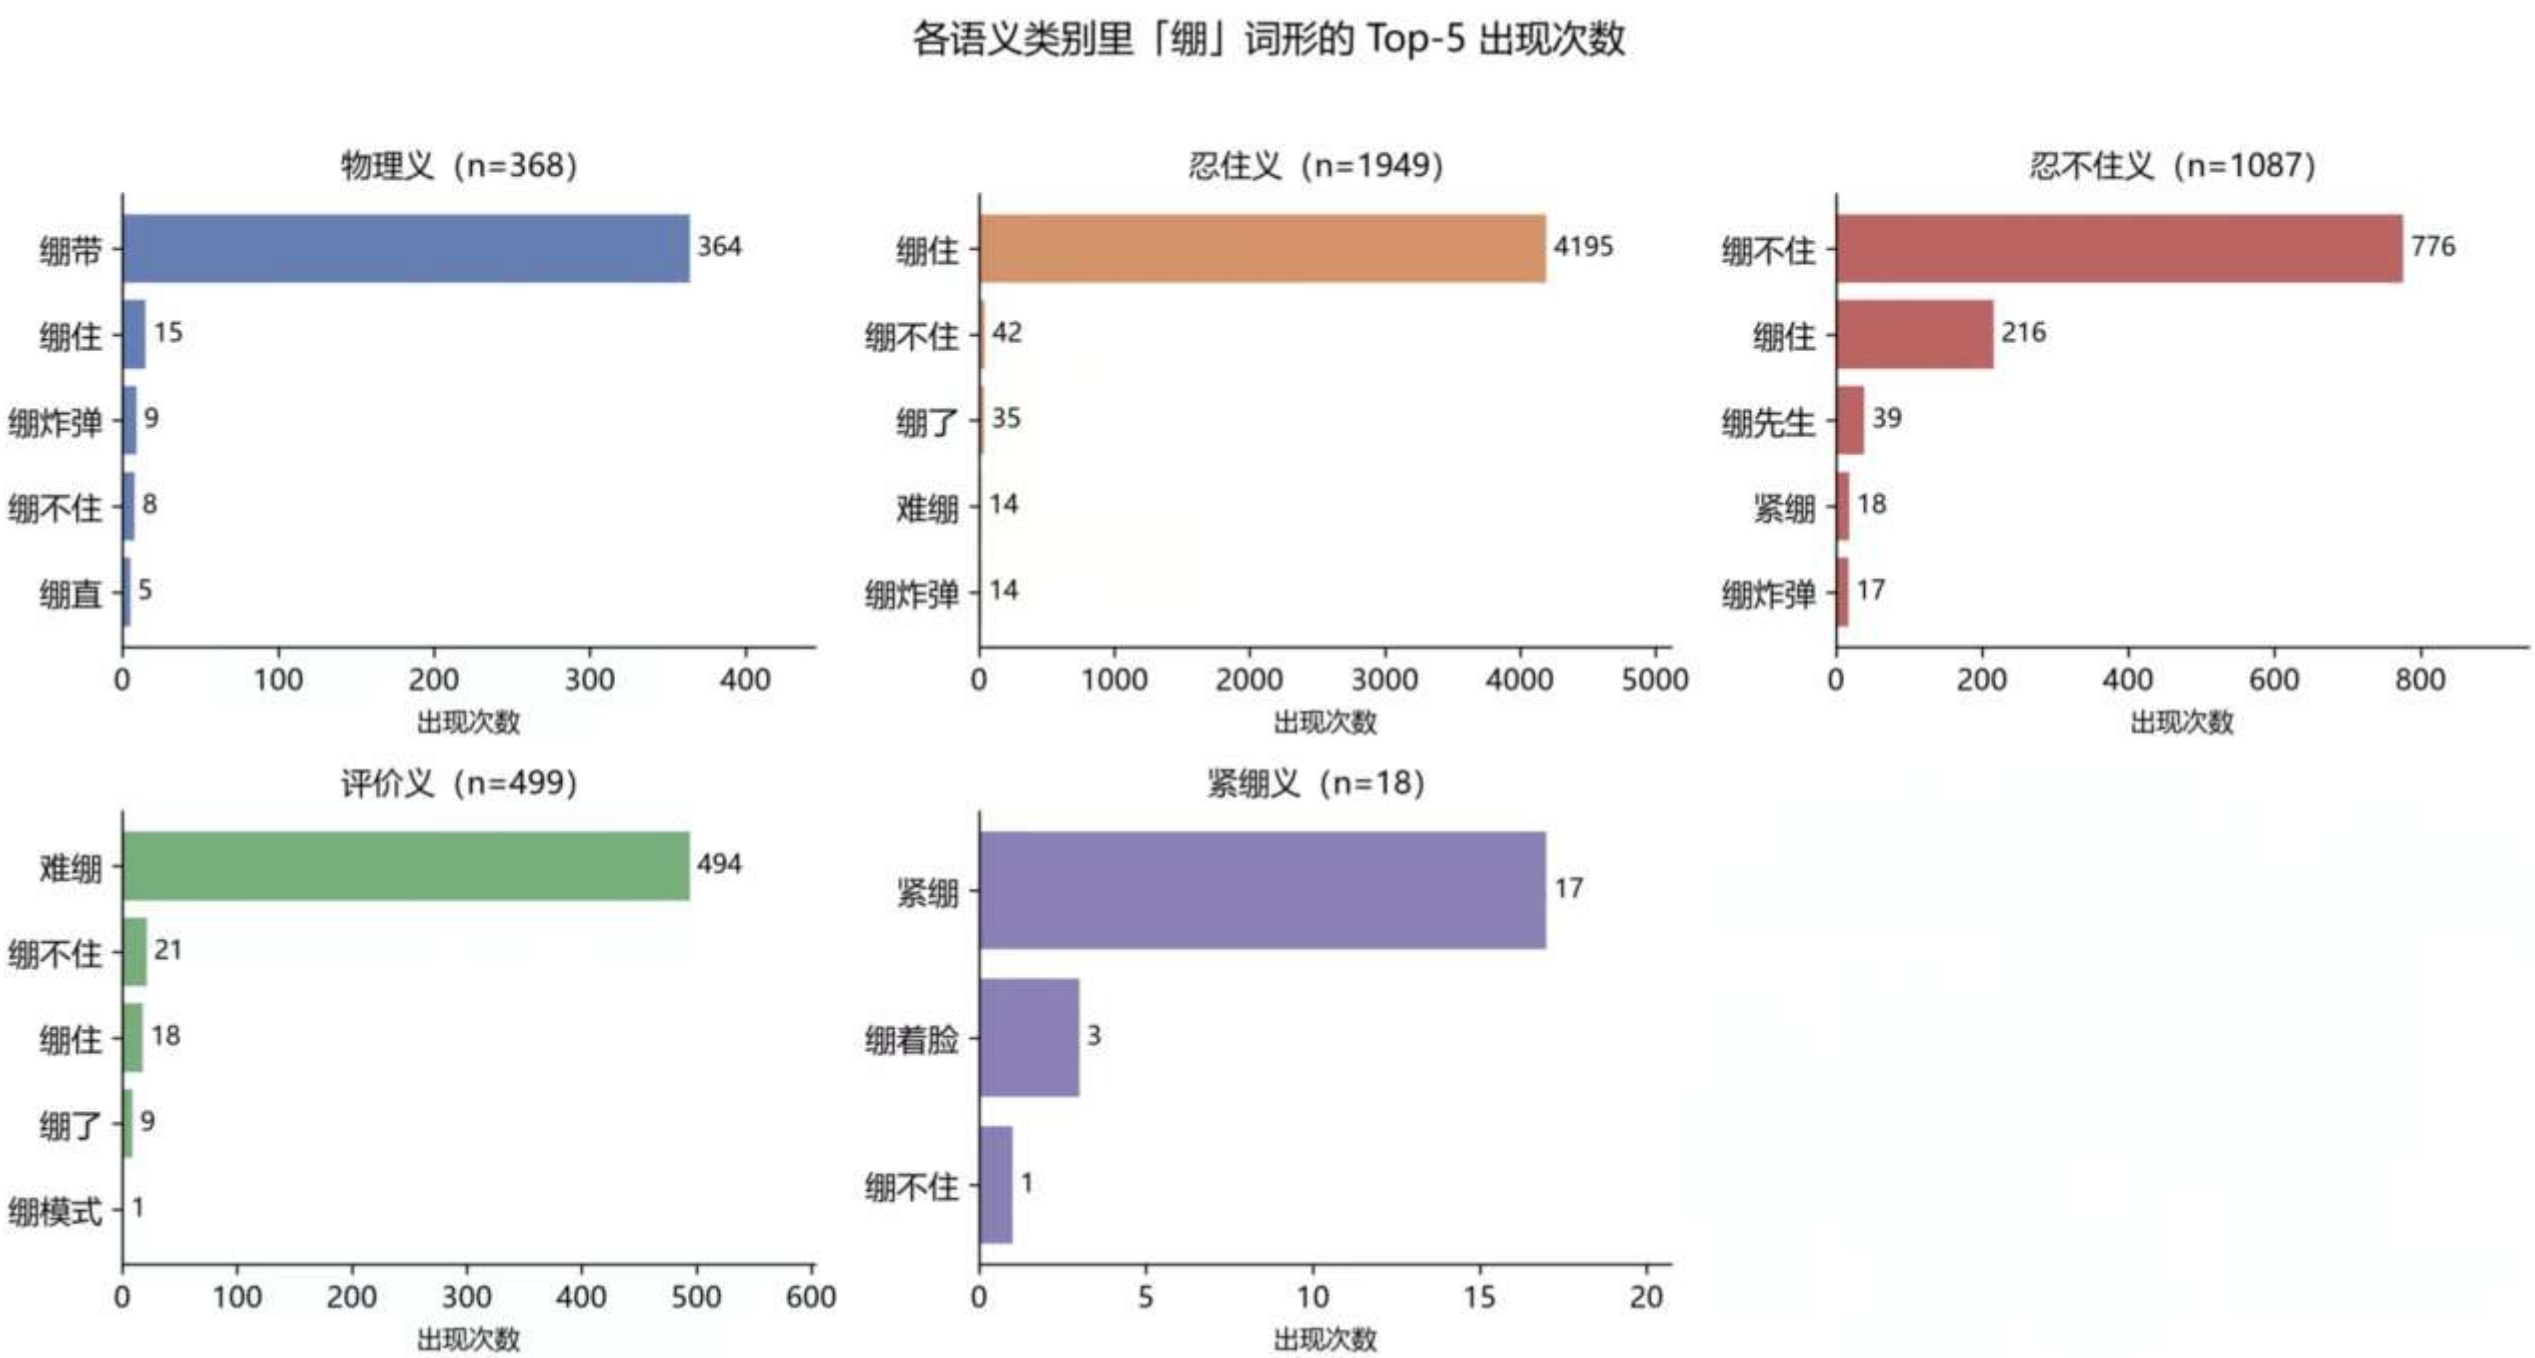
法语老师听了都得沉默三秒。哈哈哈哈哈哈哈哈哈哈哈哈🤣🤣🤣

这次是我没绷住。

“绷”

cluster	meanings
物理义	绷带bandage
忍住义	强行忍住某种情绪 Hold back/ refrain from
忍不住义	想要强行忍住，但是完全忍不住
评价义	某件事情非常令人无语、尴尬或离谱
紧绷义	面部表情、精神紧张等




各语义类别里「绷」词形的 Top-5 出现次数
物理义（n=368）
绷带
364
绷住
15
绷炸弹
9
绷不住
8
绷直
5
0
100
200
300
400
出现次数
忍住义（n=1949）
绷住
4195
绷不住
42
绷了
35
难绷
14
绷炸弹
14
0
1000
2000
3000
4000
5000
出现次数
忍不住义（n=1087）
绷不住
776
绷住
216
绷先生
39
紧绷
18
绷炸弹
17
0
200
400
600
800
出现次数
评价义（n=499）
难绷
494
绷不住
21
绷住
18
绷了
9
绷模式
1
0
100
200
300
400
500
600
出现次数
紧绷义（n=18）
紧绷
17
绷着脸
3
绷不住
1
0
5
10
15
20
出现次数

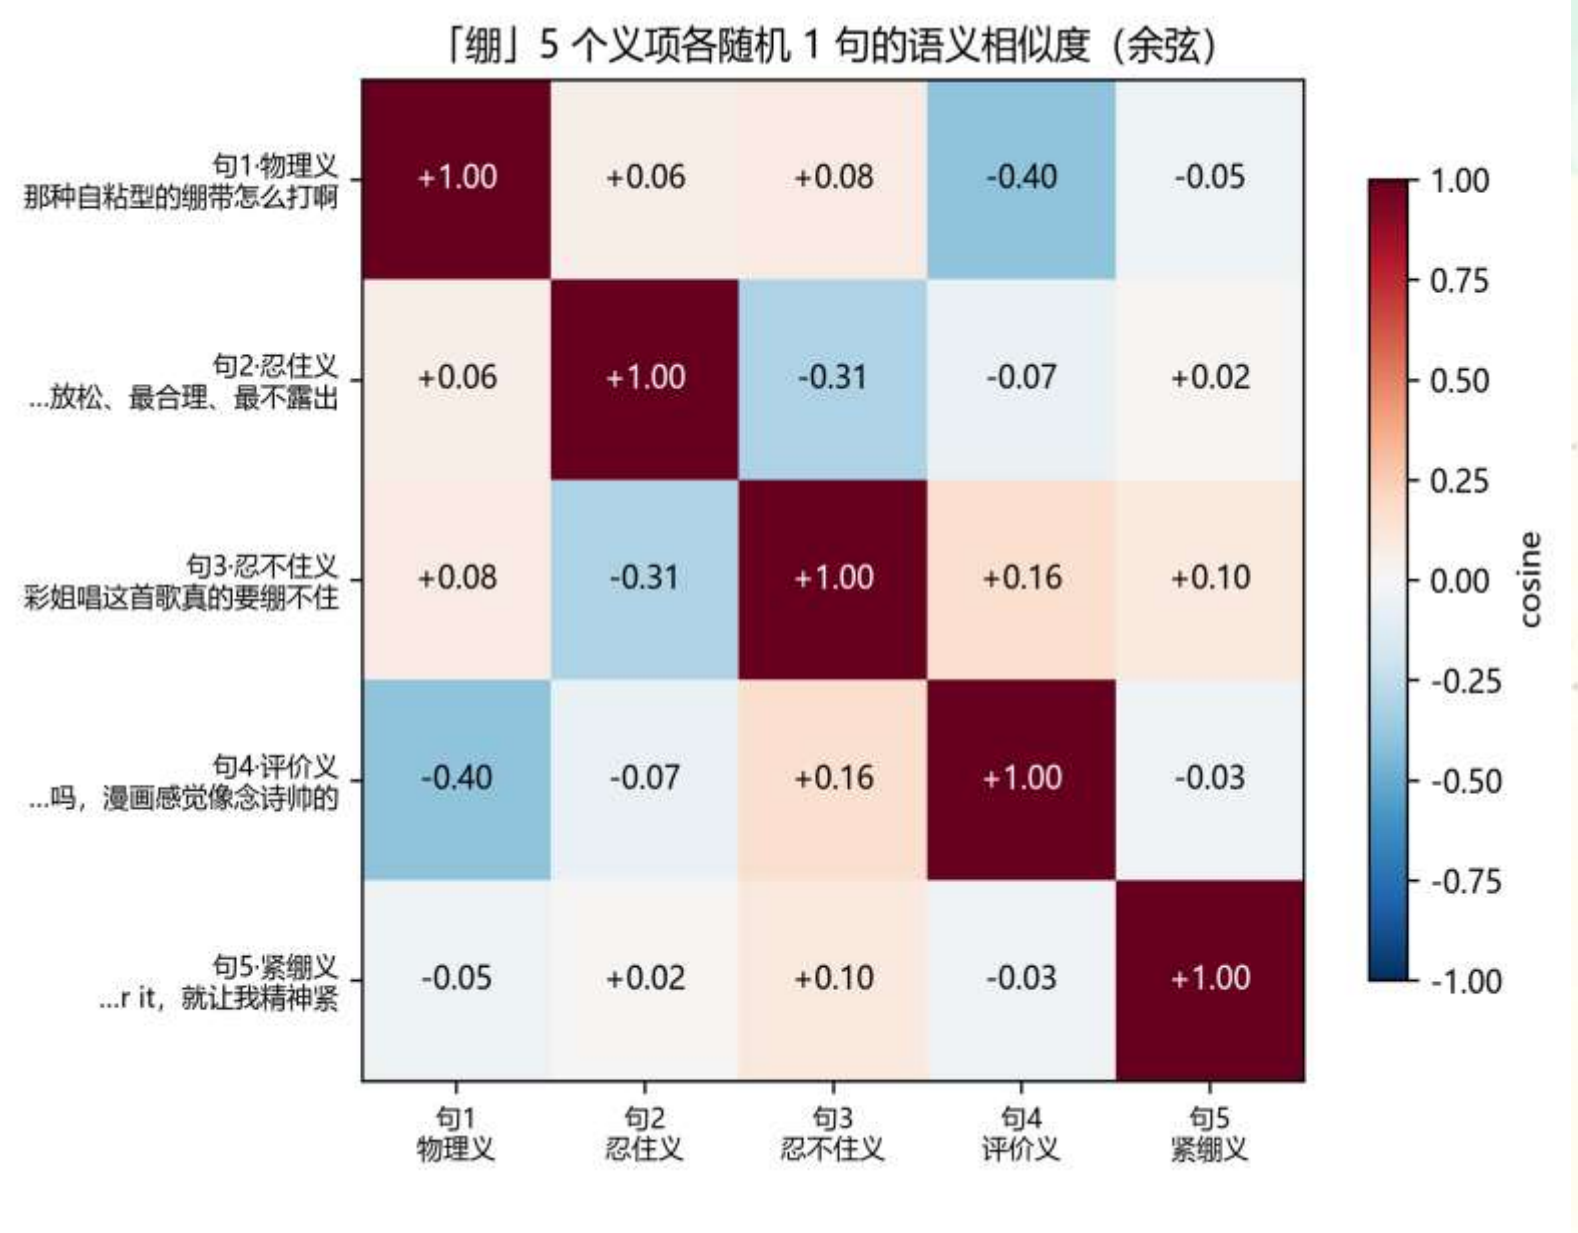
那种自粘型的**绷带**怎么打啊，是不是不如这个保护性强。业余够用了吗？[大哭]

豆包豆包告诉我怎么以最轻松最温柔最放松、最合理、最不露出破绽的方式**绷住**

彩姐唱这首歌真的要**绷不住了**

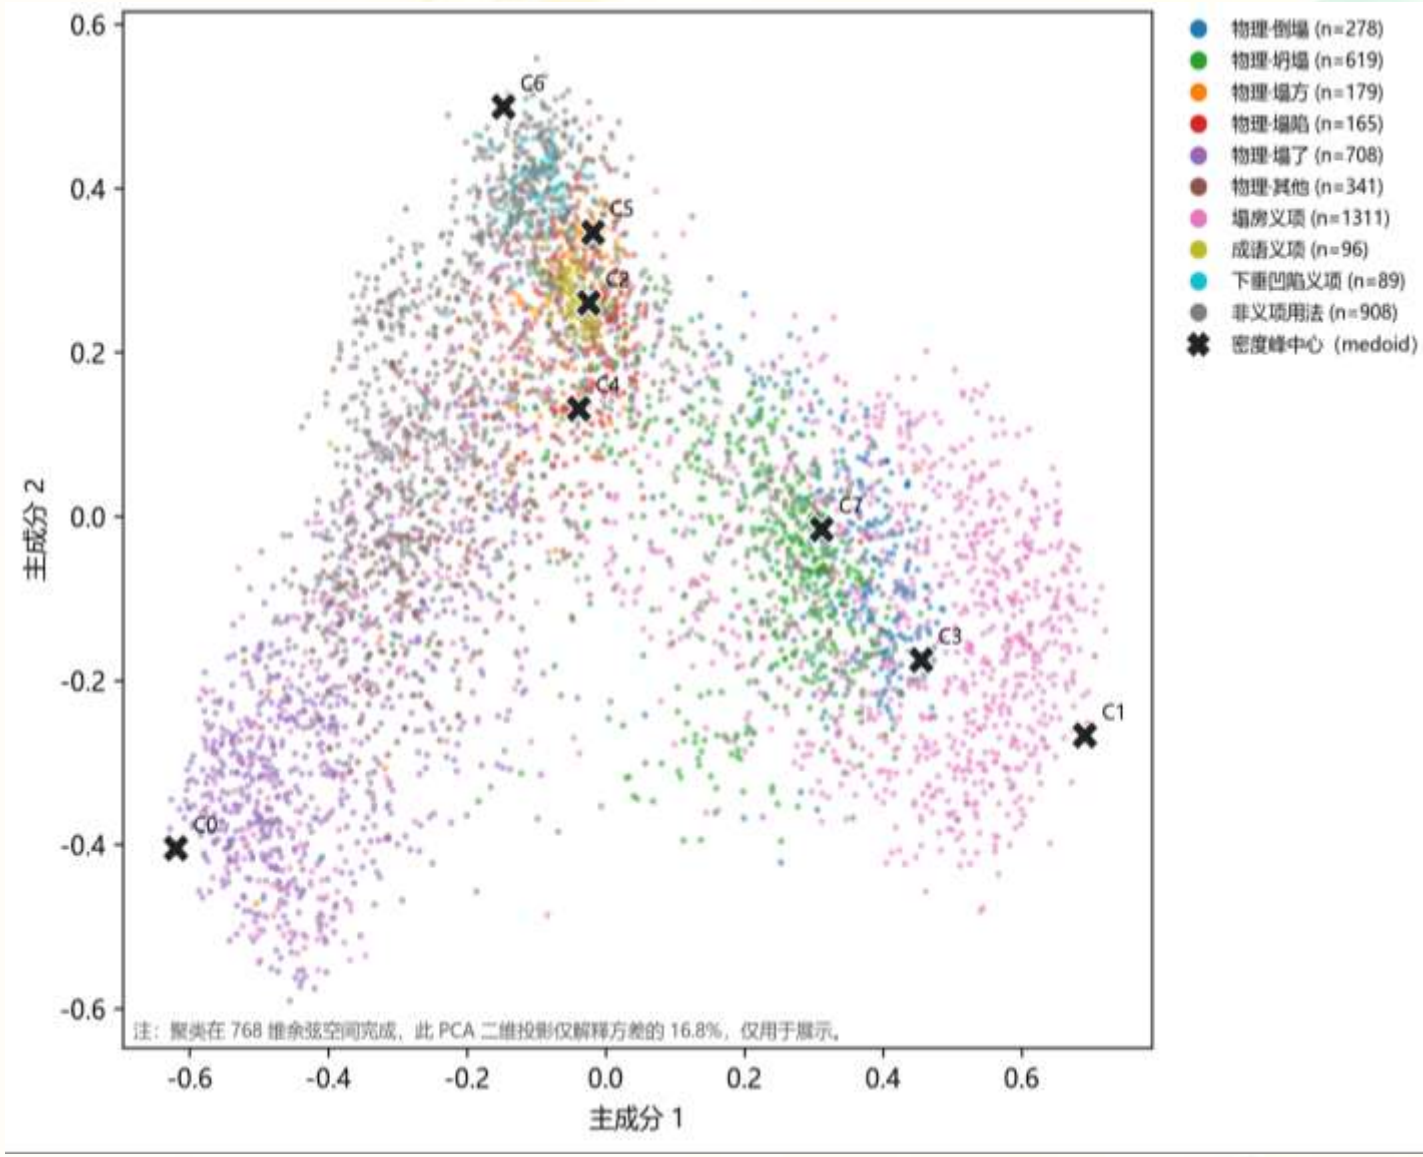
是看b格救不回来了才让和尚唱跳rap整活的吗，漫画感觉像念诗帅的，这个真的**难绷**

你这封面背景像getting over it，就让我精神**紧绷**，血压升高了

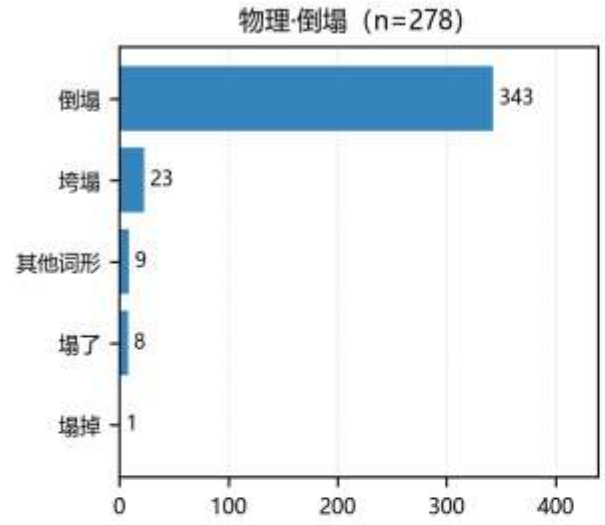


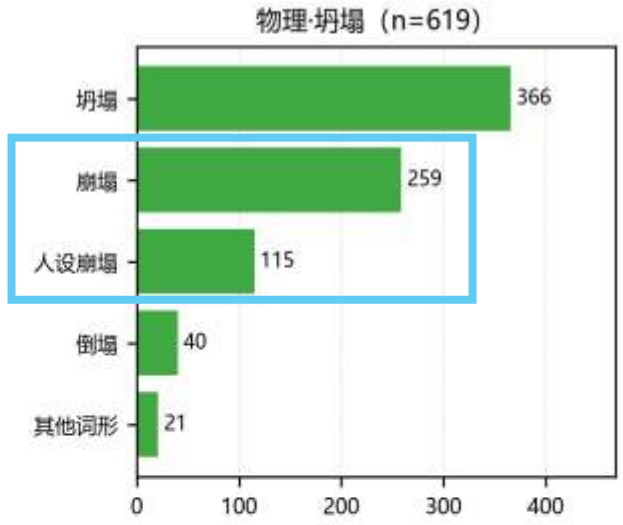
“塌”

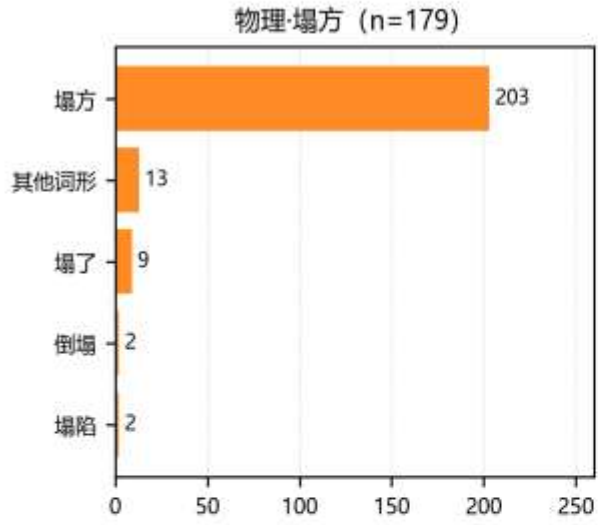
cluster	meanings
物理义	倒塌；坍塌；塌方；塌陷；塌了 collapse
塌房义	明星因负面新闻或恋情曝光导致形象崩塌
下垂凹陷义	物体或身体部位向下弯曲、下陷或失去原有的平整形态
成语义项 (以一塌糊涂为主)	形容事物、局面或状况极其混乱、糟糕，强调程度严重、状态不堪

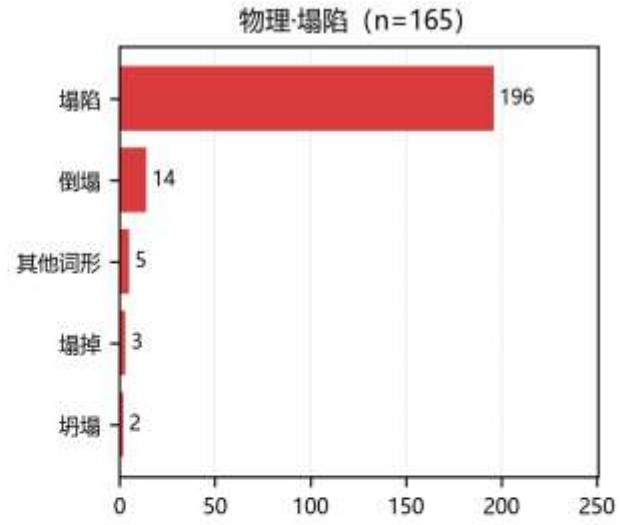


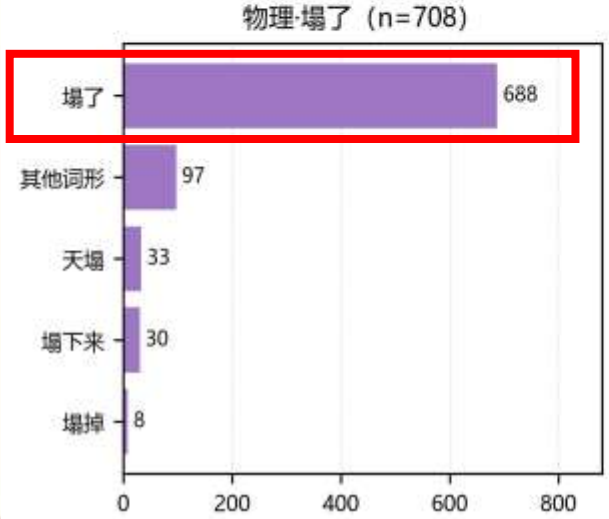
「塌」各义项中使用频率最高的前 5 个词形（次数；同一词形的屈折变体已合并，未覆盖者计入「其他词形」）

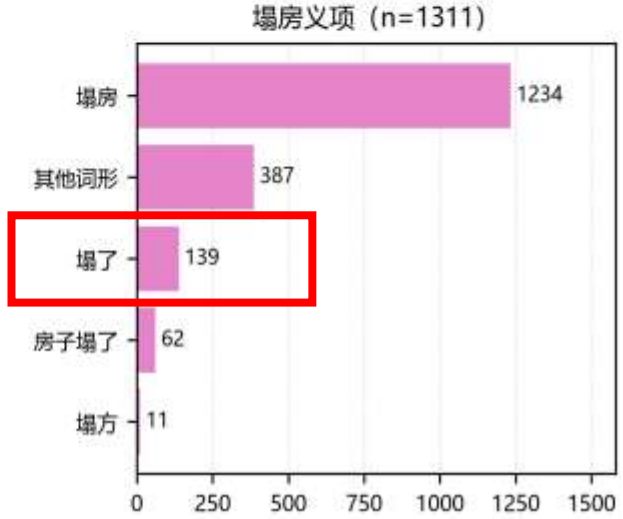


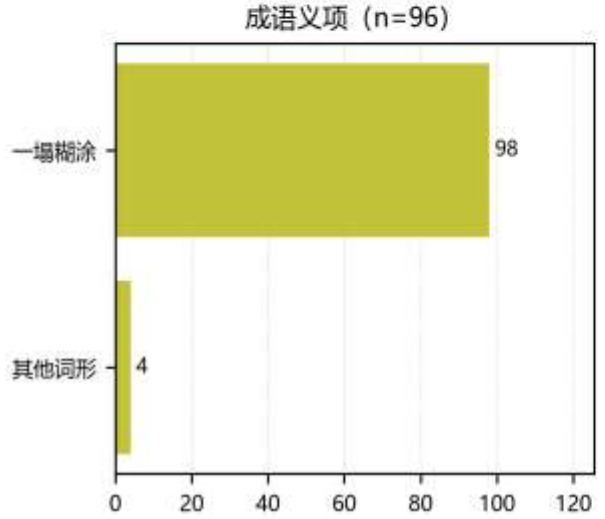


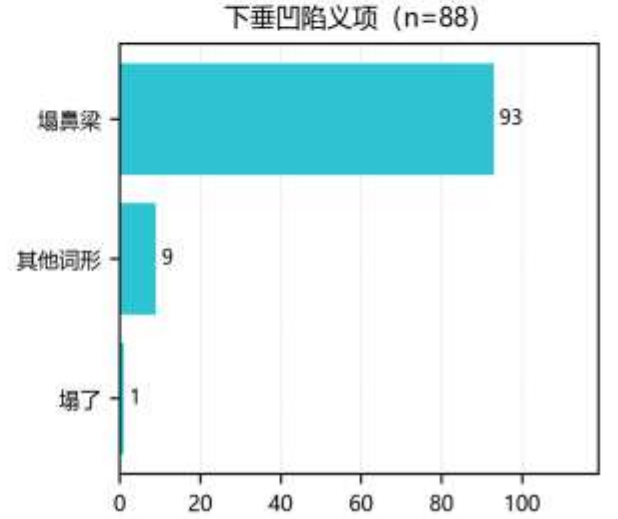












留学市场崩塌最终会影响英语主课的地位……

我也期待，但就怕像冰莲花一样夹私货人设崩塌

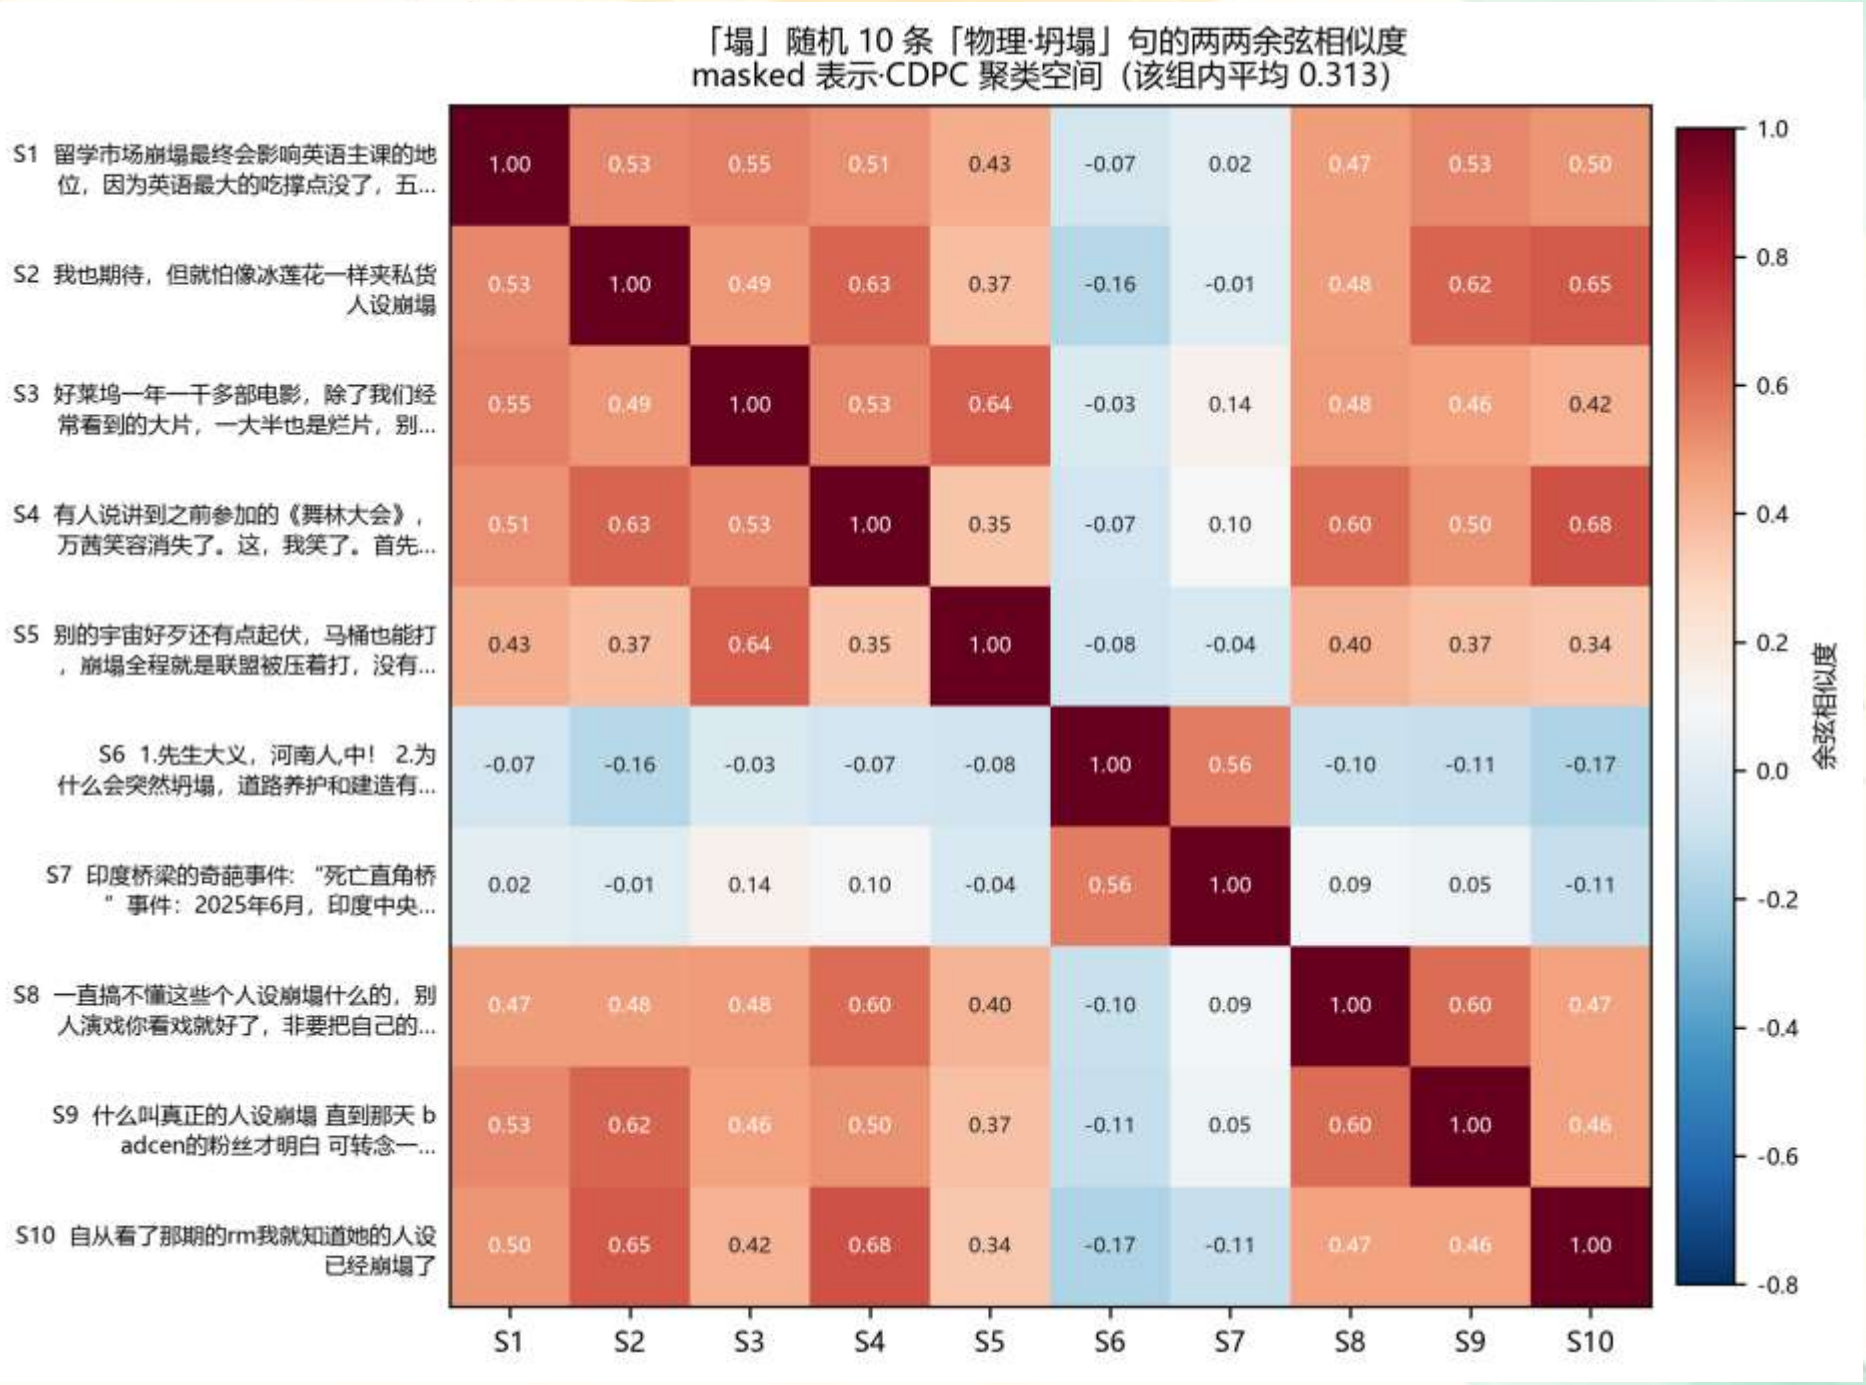
……有很多人说她人设崩塌，翻车。可是她从来没有给自己立过人设啊。人本来就是多面体……

……为什么会突然坍塌，道路养护和建造有无问题?

一直搞不懂这些个人设崩塌什么的，别人演戏你看戏就好了……

什么叫真正的人设崩塌 直到那天 badcen的粉丝才明白……

自从看了那期的rm我就知道她的人设已经崩塌了



……我的室友塌了三次房。她每说一句路人只会看热闹的时候。我都好想笑，因为我真的在看热闹……

如果lyf塌了，以后再也不关注娱乐圈了。。路人，看过他的剧和采访，感觉还是挺有趣的一个人……

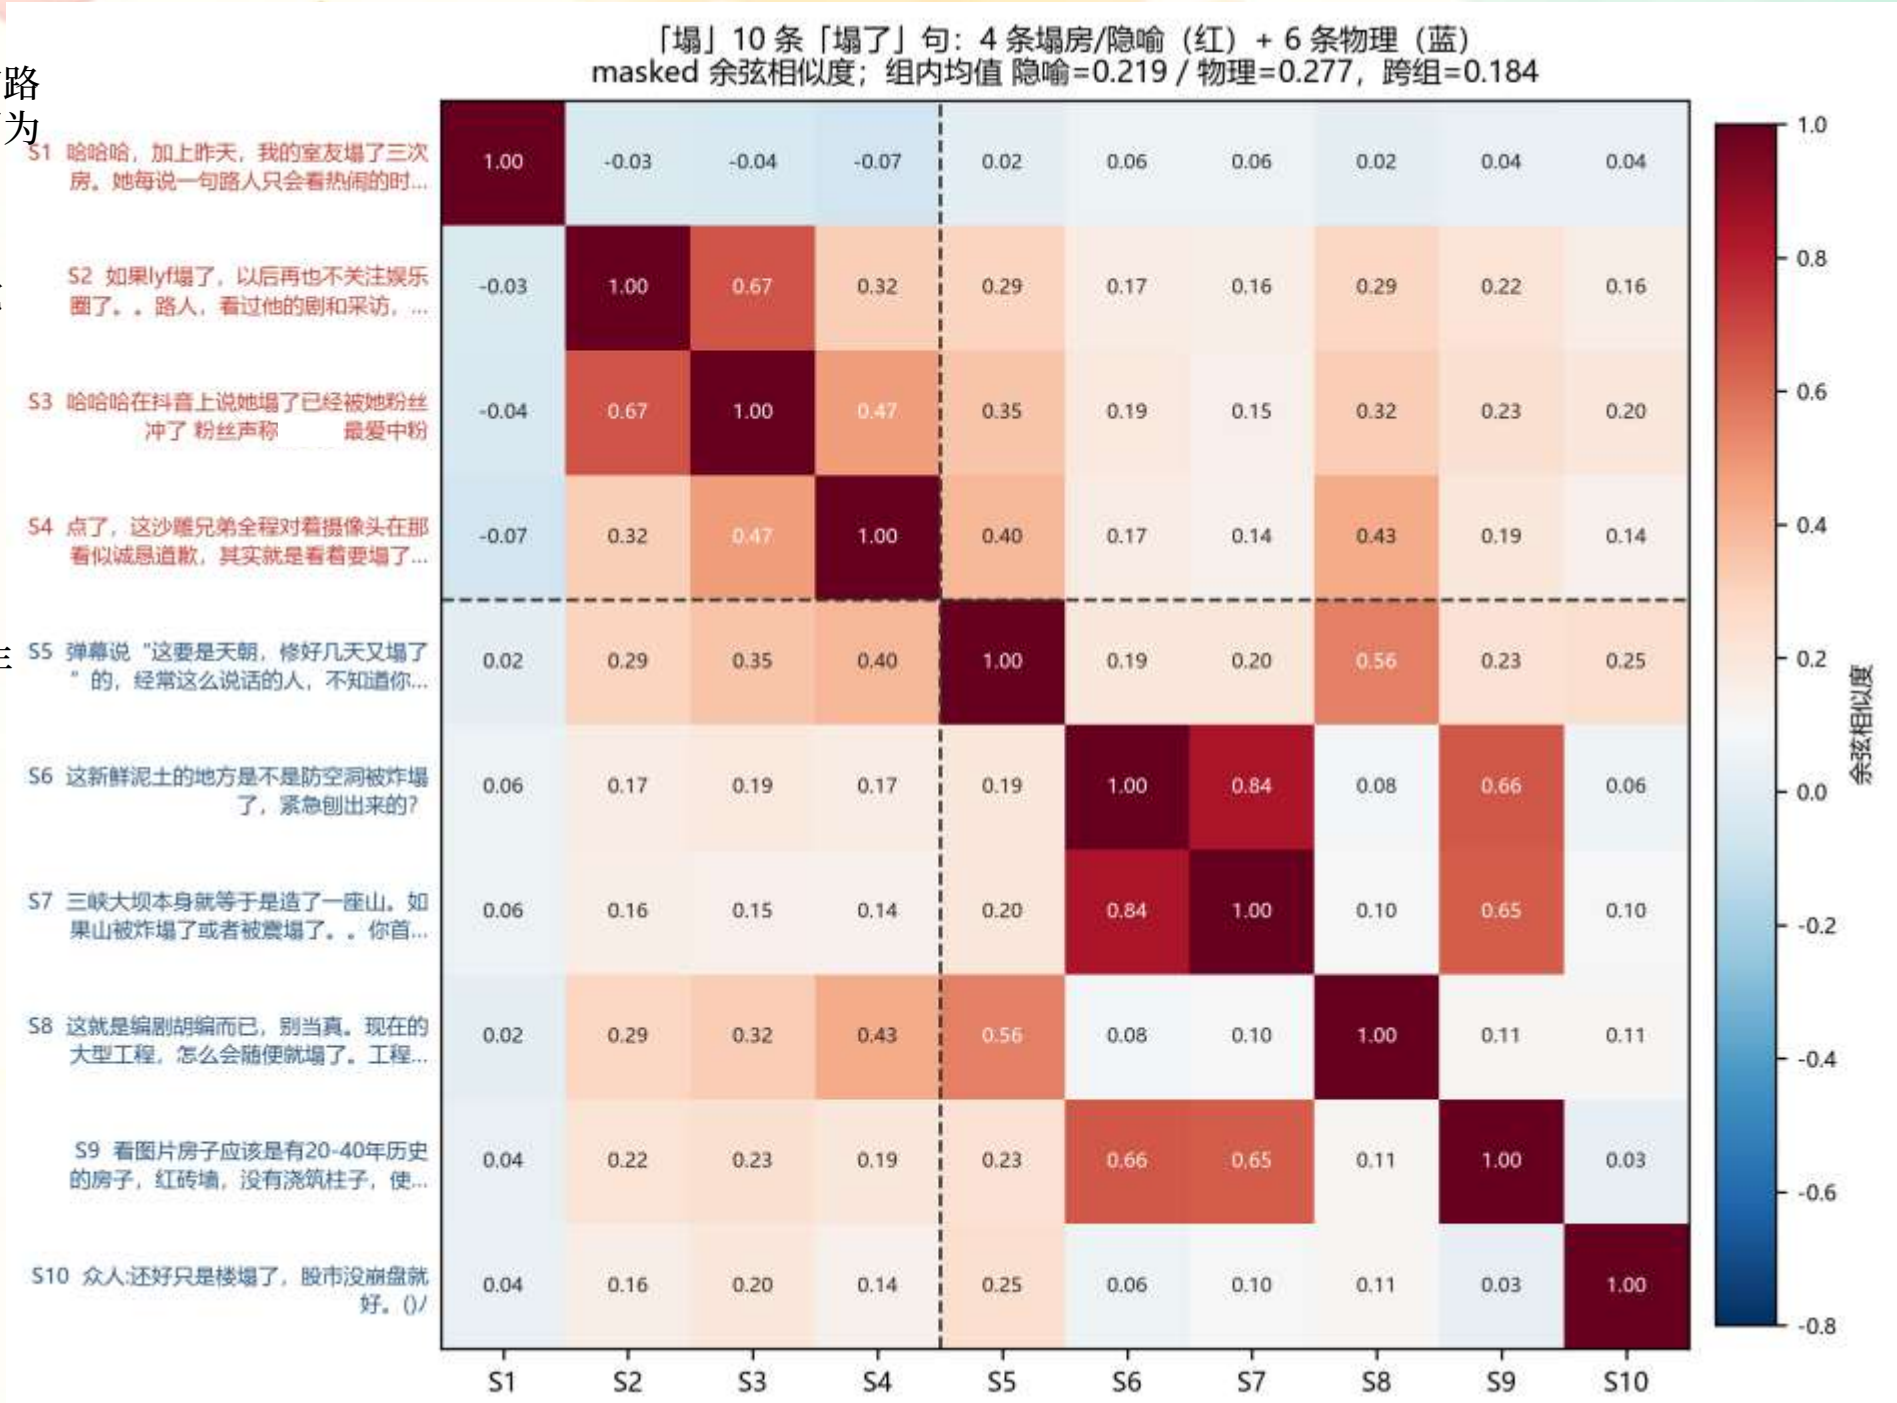
哈哈哈在抖音上说她塌了已经被她粉丝冲了 粉丝声称 最爱中粉

……这要是天朝，修好几天又塌了”的，经常这么说话的人，不知道你家的楼一年塌几次？你家的路能塌成河了吗？……

这新鲜泥土的地方是不是防空洞被炸塌了，紧急刨出来的？

三峡大坝本身就等于是造了一座山。如果山被炸塌了或者被震塌了。。你首先应该考虑的是人类的安危……

众人:还好只是楼塌了，股市没崩盘就好。(°∀°)ﾉ



Metaphors We Live By | 隐喻

Metaphor is not merely a matter of language, but a fundamental mechanism of human thought.

——George Lakoff &Mark Johnson

- Scource domain源域：指用来解释或理解另一个概念（目标域）的熟悉领域或具体事物
- Target Domain目标域：需要被理解的抽象概念领域

大楼发生崩塌	非隐喻	物理结构真实倒塌
山体崩塌	非隐喻	物理结构真实倒塌
人设崩塌	隐喻	人物形象的瓦解
信任崩塌	隐喻	抽象社会关系的瓦解

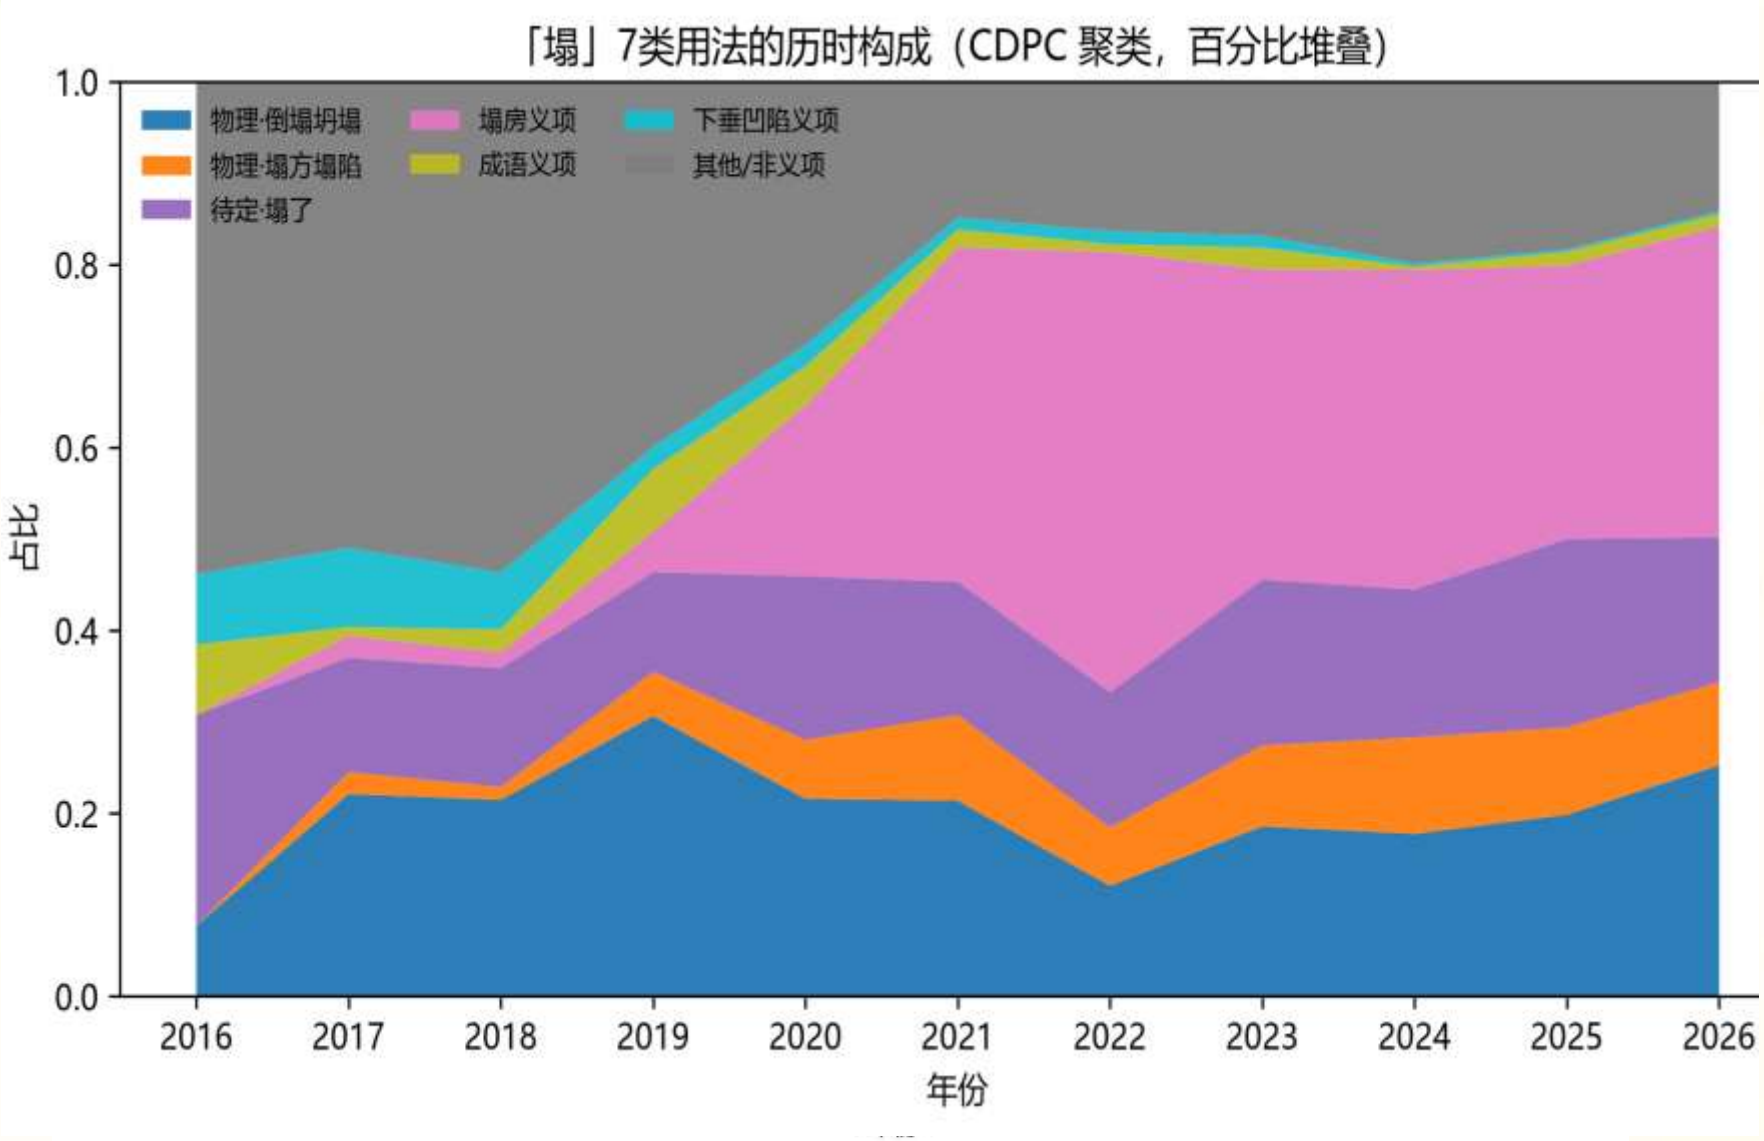
「人设崩塌」已经是一个很常见的网络表达，那么它还算不算隐喻？

Metaphor Conventionalization
隐喻常规化

It refers to the process by which a metaphorical expression gradually becomes established in everyday language. As the expression is repeatedly used and widely accepted by a speech community, it gradually becomes a conventional and familiar way of expressing meaning.

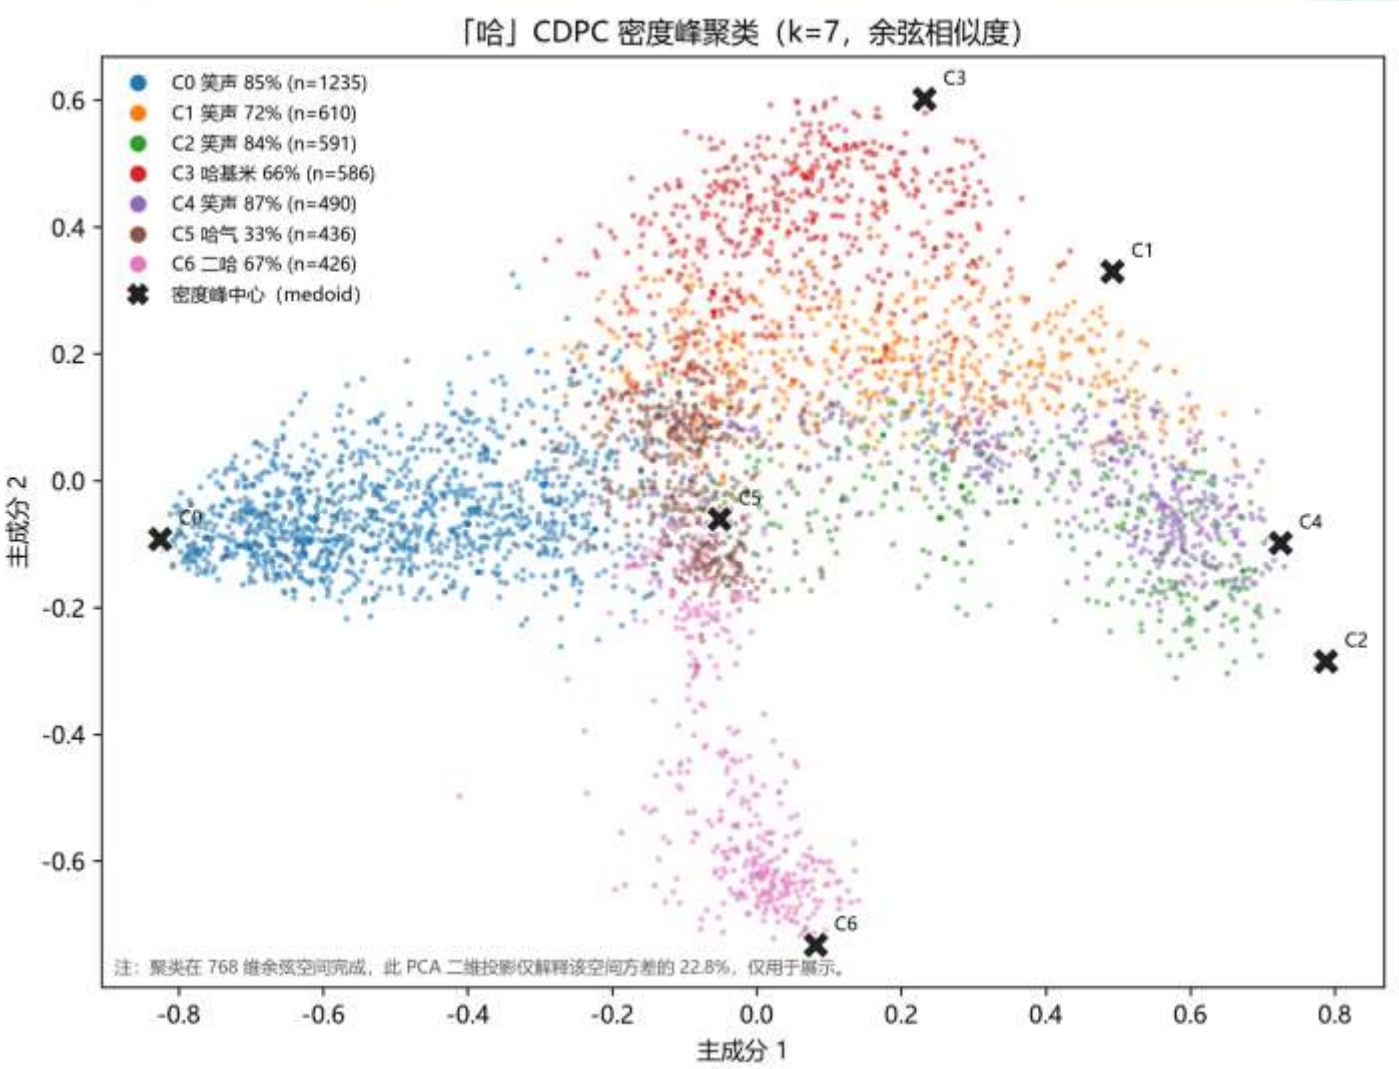


“塌”

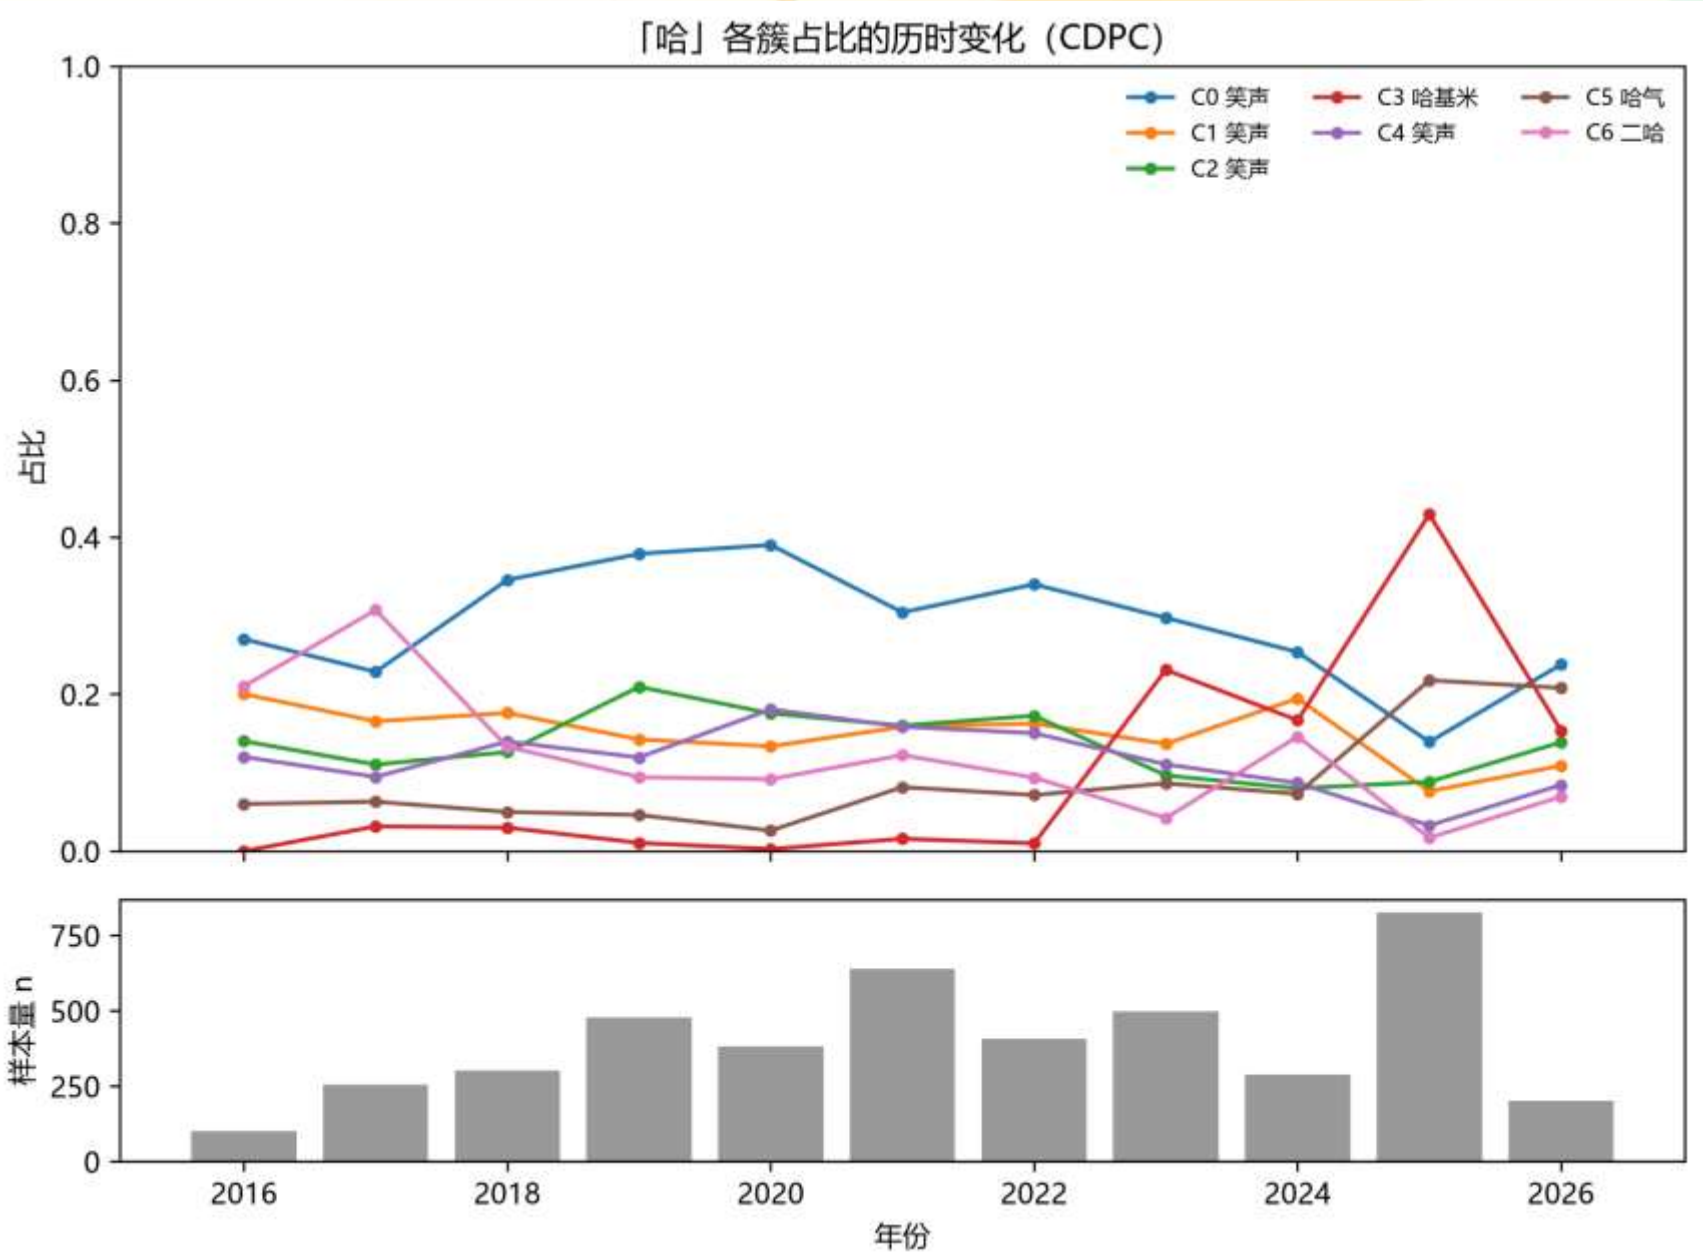

「塌」7类用法的历时构成（CDPC 聚类，百分比堆叠）
物理·倒塌坍塌
物理·塌方塌陷
待定·塌了
塌房义项
成语义项
下垂凹陷义项
其他/非义项
占比
1.0
0.8
0.6
0.4
0.2
0.0
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
2026
年份

“哈”

cluster	meanings
笑声	拟声词，用于表达笑声
哈基米	日语はちみつ（蜂蜜）的音译；后来被用于称呼猫；谷歌AI模型Gemini
哈气	张口呼气，如冬日搓手哈气取暖；猫咪感到危险时的警告信号；人生气了
二哈	哈士奇



“哈”


「哈」各簇占比的历时变化（CDPC）
C0 笑声
C1 笑声
C2 笑声
C3 哈基米
C4 笑声
C5 哈气
C6 二哈
占比
1.0
0.8
0.6
0.4
0.2
0.0
样本量 n
750
500
250
0
2016
2018
2020
2022
2024
2026
年份

“哈基米”

蜂蜜honey

日语「はちみー」（Hachimi），与《赛马娘》角色歌曲中的蜂蜜饮品表达有关。

Semantic Shift

Pragmatic Change

猫Cat

哈基米南北绿豆

衍生出“哈基米南北绿豆”等网络固定表达。

Phonological Association

Metonymy?

- Gemini → 猫娘形象
- 猫娘形象 → 猫
- 猫 → 哈基米

AI模型Gemini







“哈气”

[2026-02-27] 我这辈子没听她喵过一声…在家门口有任何动静的时候冲过去开始呜噜呜噜…（不会**哈气**，也不会老吴老吴）…

[2026-02-10] 张大口，**哈气**吧

[2025-08-25] 猫 对 汽车 使用 **哈气**！ "貌似并没有什么用..." 汽车 对 猫 使用 撞击！"效果拔群！"

[2025-04-24] 其实没**哈气**，只是在打哈气，被我拍到了

[2025-09-13] 圆头，你要记着，一个人在外，不要**哈气**

[2025-10-29] 不会**哈气**学哈气

张口呼气，如冬日搓手哈气取暖

↓ **Semantic Shift**

猫咪感到危险时的警告信号

↓ **Semantic Broadening**

人生气了

PART Five

Limitations & Extensions

Limitations

Model Limitations
模型局限

- Outdated pre-trained models and limited knowledge of emerging expressions.
- As a result, it may fail to adequately capture the contextual and semantic nuances of recently emerging expressions.

Uneven Data Distribution
数据分布不均

- The number of collected instances varies considerably across target words.
- Some words have insufficient historical data, making diachronic comparisons less reliable.
- Data collected from 2026 is incomplete, which may affect the analysis of recent semantic trends.

Data Source Bias
数据来源单一

The corpus was collected primarily from Bilibili, without incorporating data from other major platforms such as Weibo, Douyin, and Xiaohongshu.

Methodological And Analytical Reliability
对于DSH有过多依赖

A substantial proportion of the coding and data-processing tasks relied on DeepSeek Harness.

Extensions

➢ Speech Model And Speech Understanding

- When acoustic information is insufficient, how does contextual information contribute to speech understanding?
- How does the model distinguish the meaning differences resulting from the pronunciation variations between dialects and standard language?

➢ Cross-lingual Transferability

How does word-embedding quantify corss-lingual representation alignment?

E.g. nostalgia　vs.　怀旧

To what extent do they share the same meaning?

WORK REPORT

感谢大家的观看与聆听

胡海音　刘玉　糜欣贝

时间：2026.11